



UNIVERSIDAD ESAN
FACULTAD DE INGENIERÍA
INGENIERÍA DE TECNOLOGÍAS DE INFORMACIÓN Y SISTEMAS

Desarrollo de un Sistema de detección haciendo uso de Deep Learning y Visión por Computadora para el pre-diagnóstico del Cáncer de Piel de tipo Melanoma

Trabajo de investigación para el curso de Trabajo de Tesis I

Nombre alumno: Castro Tuesta Maria Elizabeth

Asesor: Marks Calderón

Lima, 3 de junio de 2024

Índice general

Índice de Figuras	4
Índice de Tablas	6
1. PLANTEAMIENTO DEL PROBLEMA	7
1.1. Descripción de la Realidad Problemática	7
1.2. Formulación del Problema	9
1.2.1. Problema General	10
1.2.2. Problemas Específicos	10
1.3. Objetivos de la Investigación	10
1.3.1. Objetivo General	10
1.3.2. Objetivos Específicos	10
1.4. Hipótesis	11
1.4.1. Hipótesis General	11
1.4.2. Hipótesis Específicas	11
1.4.3. Matriz de Consistencia	11
1.5. Justificación de la Investigación	12
1.5.1. Teórica	12
1.5.2. Práctica	12
1.5.3. Metodológica	12

1.6. Delimitación del Estudio	13
1.6.1. Espacial	13
1.6.2. Temporal	13
1.6.3. Conceptual	13
2. MARCO TEÓRICO	14
2.1. Antecedentes de la investigación	14
2.1.1. Deep Learning-Based Transfer Learning for Classification of Skin Cancer (jain2021deep)	14
2.1.2. Skin cancer classification via convolutional neural networks: systematic review of studies involving human experts (haggenmuller2021skin)	15
2.1.3. An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models (ali`2021enhanced)	17
2.1.4. Design of a tool for the classification of skin cancer images using Deep Neural Networks (DNN) (vargas`2021diseno)	18
2.1.5. Diagnosis of skin cancer using machine learning techniques (murugan`2021diagnosis)	20
2.1.6. Multiclass skin cancer classification using EfficientNets – a first step towards preventing skin cancer (ali`2022multiclass)	22
2.1.7. Skin cancer classification using explainable artificial intelligence on pre-extracted image features (khater2023skin)	24
2.1.8. An improved transformer network for skin cancer classification (xin2022improved)	25
2.1.9. Uncertainty quantification in skin cancer classification using three-way decision-based Bayesian deep learning (abdar2021uncertainty)	27
2.1.10. A multi-class skin Cancer classification using deep convolutional neural networks (chaturvedi2020multi)	28
2.2. Bases Teóricas	30
2.2.1. Inteligencia Artificial	30
2.2.2. Aprendizaje Automático (Machine Learning)	30
2.2.3. Aprendizaje Profundo (Deep Learning)	30

2.2.4. Computer Vision	31
2.3. Marco Conceptual	31
2.3.1. El Cáncer	31
2.3.2. Cáncer de Piel	31
2.3.3. Sintomas del Cáncer de Piel	32
2.3.4. Tipos del Cáncer de Piel	32
2.3.5. Melanoma	32
2.3.6. Formas de diagnosticar el cáncer de piel	33
Anexos	34
A. Anexo I: Árbol de Problema	35
B. Anexo II: Árbol de Objetivo	36
C. Anexo II: Matriz de Consistencia	37
D. Anexo II: Resumen de Papers investigados	39

Índice de Figuras

1.1. Predicción de número de casos acumulado de cancer a nivel mundial. Fuente: stadisite`cancer	7
1.2. Pronóstico de radiación UV. Fuente: SENAMHI`uv	8
1.3. Metodo del primer diagnostico DEL CANCER.PERU 2019-2022: cancer`diagnostico	9
2.1. Comparación de los resultados de los modelos utilizados. Fuente: jain2021deep	15
2.2. Represación de los 19 estudios. Fuente: haggenmuller2021skin	16
2.3. Modelo de arquitectura propuesto DCNN .Fuente: ali`2021enhanced	18
2.4. Resultados de modelo DCNN comparandolo con otros modelos Fuente: ali`2021enhanced	18
2.5. Comparacion de los resultados del modelo MobileNet V1 y Inception V3 con diferentes versiones. Fuente: vargas`2021diseno	20
2.6. Grafica de la Metodología usada . Fuente: murugan`2021diagnosis	21
2.7. Comparación de los modelo empleados con las tres técnicas para la extracción de características. Fuente: murugan`2021diagnosis	22
2.8. Comparación de los modelo empleados con las tres técnicas para la extracción de características. Fuente: ali`2022multiclass	23
2.9. Comparación de los modelo empleados con las tres técnicas para la extracción de características. Fuente: ali`2022multiclass	25
2.10. Resultados de los Modelo empleados. Fuente: xin2022improved	26
2.11. Resultados de los Modelo empleados. Fuente: abdar2021uncertainty	28
2.12. Resultados de los Modelo empleados. Fuente: chaturvedi2020multi	29

A.1. Árbol de Problema. Fuente: Elaboración propia	35
B.1. Árbol de Problema. Fuente: Elaboración propia	36

Índice de Tablas

C.1. Matriz de consistencia. Fuente: Elaboración propia	38
D.2. Cuadro Resumen de Papers investigados. Fuente: Elaboración propia	40

Capítulo 1

PLANTEAMIENTO DEL PROBLEMA

1.1. Descripción de la Realidad Problemática

Desde inicios de la historia, las enfermedades infecciosas hasta crónicas han sido parte de la humanidad y han afectado desde pueblos hasta naciones. No obstante, gracias al avance de la medicina se ha podido comprender muchas de estas enfermedades, logrando mejorar la salud de muchas personas o su completa recuperación. Pero en el mejor de los casos eliminada o controlada por completo, el caso más conocido es la viruela que fue erradicada en 1980 debido a un programa mundial de vacunación.



Figura 1.1: Predicción de número de casos acumulado de cancer a nivel mundial. Fuente: [stadistic cancer](#)

Sin embargo, una enfermedad que ha afectado durante siglos a la humanidad es el cáncer. Este se caracteriza por su capacidad de alterar el equilibrio de las células del cuerpo humano, provocando un crecimiento anormal y descontrolado de las zonas afectadas a tal grado que puede llegar a invadir otras partes del cuerpo. La Organización mundial de la salud (OMS) afirma que el cáncer es la segunda causa muerte más frecuente en América y una las principales a nivel mundial. En estima que en el año 2022 hubo 20 millones de nuevos casos y 9,7 millones de muertes. Como se pude observar en la figura 2.12, según el estudio de Statista publicado en el año 2023 se proyecta que el número de nuevos casos de cáncer crecerá notoriamente en los próximos 20 años. (OMS' cancer)

Entre los tipos más comunes de cáncer se encuentra el que afecta a la piel el cual se puede contraer a cualquier edad; sin embargo, las personas de mayor riesgo son las que estan expuestos por tiempos prolongados al sol y poseen piel clara. La principal causa es la exposición a la radiación ultravioleta o fuentes artificiales. Según American Cancer Society para el año 2023 morirán aproximadamente que morirán aproximadamente 7,990 personas y aproximadamente aparecerán 97,610 nuevos casos.

Si bien la mayoría de los casos se puede tratar sin complicaciones, existe un porcentaje en el cual puede llegar a ser peligro y potencialmente mortal. Esto principalmente debido a que no es detectado a tiempo o no se cuenta con dermatólogos especializados en esta área.




Figura 1.2: Pronóstico de radiación UV. Fuente: SENAMHI'uv

En el caso del Perú, el cáncer de piel está en aumento, especialmente debido a la alta incidencia de radiación ultravioleta (UV) en muchas regiones del país como podemos ver en la figura 1.2 el nivel de radiación ultravioleta el día 21 de abril del 2024 (SENAMHI^{uv}) y la falta de conciencia sobre la protección solar adecuada. Agregando, la detección temprana y el tratamiento oportuno de esta enfermedad son difíciles por la falta de acceso a servicios de salud especializados en algunas áreas rurales y remotas. Como podemos observar en la siguiente figura 1.3 La cual nos indica que el 73 % de los casos fueron cuando acudieron a un establecimiento de salud en el momento que ya presentaron síntomas muy notorios de cáncer, haciendo evidencia de que el fue diagnosticado de forma tardía. (**cancer' diagnostico**)




Figura 1.3: Metodo del primer diagnostico DEL CANCER.PERU 2019-2022: **cancer' diagnostico**

Aun así, si llegaron a la cita clínica que solicitaron, la probabilidad que esta sea en un ambiente que tenga los recursos necesarios y que sea realizada por un médico dermatólogo especializado en el área, es más seguro que sea considerado como una lesión menor por exposición al sol que sea considerado como un tipo de cáncer de piel.

Esto principalmente por la complejidad de poder identificarlo, algunas razones son: variedad de tipos de cáncer, estos pueden manifestarse de maneras diferentes en cualquier parte del cuerpo; falta de síntomas, pueden no presentar síntomas o pueden ser similares a los de otras enfermedades menos graves; factores de riesgo, falta del historial del paciente puede hacer que se puedan equivocar en el diagnostico.

1.2. Formulación del Problema

Para realizar la formulación de los problemas del presente trabajo, se elaboró un árbol de problemas (Anexo A.1).

1.2.1. Problema General

¿Es posible realizar un pre-diagnostico de cáncer de piel en el Perú haciendo uso de técnicas de Deep Learning y computer vision que identifique el Cáncer de Piel de tipo melanoma a partir de imágenes dermatológicas?

1.2.2. Problemas Específicos

- ¿Cuáles son los algoritmos de Deep Learning que pueden clasificar con precisión el cáncer de piel de tipo melanoma en imágenes dermatológicas?
- ¿Cómo evaluar la precisión de los modelos de Deep Learning en la detección de cáncer de piel de tipo melanoma?
- ¿Qué tipo de ruido puede haber en las imágenes dermatológicas que dificulte la detección del cáncer de piel de tipo melanoma?
- ¿Cómo afecta la disponibilidad de la base de datos de imágenes dermatológicas en el desarrollo de un sistema de detección del cáncer de piel de tipo melanoma?

1.3. Objetivos de la Investigación

Para realizar la formulación de los problemas del presente trabajo, se elaboró un árbol de objetivos (Anexo [B.1](#)).

1.3.1. Objetivo General

Desarrollar un sistema que identifique el cáncer de piel de tipo melanoma a partir de imágenes dermatológicas mediante el uso de técnicas de Deep Learning y computer vision.

1.3.2. Objetivos Específicos

- Identificar los algoritmos de Deep Learning más adecuados para la clasificación del Cáncer de Piel de tipo melanoma en imágenes dermatológicas.
- Identificar qué métricas usar para evaluar el rendimiento del modelo de Deep Learning en la detección del cáncer de piel de tipo melanoma

- Identificar que preprocesamiento reduce el impacto de los diferentes tipos de ruidos encontrados en las imágenes dermatológicas de cáncer de piel de tipo melanoma.
- Identificar la base de datos de imágenes dermatológicas, mejorara el desarrollo del modelo de detección del cáncer de piel de tipo melanoma.

1.4. Hipótesis

1.4.1. Hipótesis General

La aplicación de técnicas de Deep Learning en el análisis de imágenes dermatológicas permitirá entrenar un modelo capaz de identificar el cáncer de piel de tipo melanoma.

1.4.2. Hipótesis Específicas

- La implementación del algoritmo de Deep Learning adecuado permitirá clasificar con precisión el Cáncer de Piel de tipo melanoma en imágenes dermatológicas.
- Indentificar las métricas nos proporcionara una mejor evaluación del modelo de Deep Learning en la detección de cáncer de piel de tipo melanoma.
- Identificar los tipos de ruidos en las imágenes dermatológicas permitirá tener un modelo con mayor precisión en la detección de cáncer de piel de tipo melanoma.
- Indentificar la base de datos de imágenes dermatológicas mejora la precisión en la detección del cáncer de piel de tipo melanoma.

1.4.3. Matriz de Consistencia

Esta fue elaborada para la presente investigación en el cual encontrarn los problemas, objetivos e hipótesis descritas anteriormente en el Anexo [C.1](#).

1.5. Justificación de la Investigación

1.5.1. Teórica

Este trabajo de investigación se realiza con la finalidad de apoyar la falta de dermatólogos especialistas en ciertas regiones del Perú.

Haciendo uso de tecinas de Deep Learning en el análisis de imágenes dermatológicas puede predecir si un usuario pueda estar desarrollando cáncer de piel y predecir el tipo.

1.5.2. Práctica

Existen diversas investigaciones donde se realiza pre-diagnosticos o clasificación de que tipo de cáncer de piel se muestra en la imagen. No obstante, en este caso se trabajará con data etiquetada por dermatólogos peruanos especializados en el área. Esto con la finalidad de tener una mayor precisión en los resultados.

Ademas que se planteara la realización de un prototipo de un sistema que integra el modelo propuesto, el cual funciona en tiempo real capturando la información de las características solamente recibiendo como entrada una imagen de la lesión.

1.5.3. Metodológica

. La implementación de este modelo puede apoyar a los dermatólogos que no tienen tanta experiencia en esta área a realizar un mejor diagnóstico, ya que si se puede detectar a tiempo se puede realizar un tratamiento efectivo. Es importante destacar que esta enfermedad no es mortal; no obstante, existen casos en donde esta enfermedad puede presentar complicaciones.

Por ello la investigación deberá analizar los resultados para mejorar la capacidad de predicción y la clasificación de los modelos de detección.

1.6. Delimitación del Estudio

1.6.1. Espacial

Para la investigación, se consideraron las investigaciones de distintos países. Sin embargo, los artículos en general se tomaron en cuenta palabras los de idioma inglés. Además de solo adquirir los que hacen uso de modelos de machine learning o deep learning.

1.6.2. Temporal

Los datos que serán necesarios para el siguiente estudio serán base de datos con imágenes de cáncer de piel(melanoma y no melanoma) las cuales deben estar etiquetadas si son positivas o negativas. Para la data de entrenamientos se usara un conjunto de datos llamado “Skin Cancer MNIST: HAM10000” del año 2019. Para luego realizar una base de datos con imágenes de pacientes peruanos de una zona específica del Perú.

1.6.3. Conceptual

Esta investigación se enfocará en la implementación de un modelo que logre detectar si una lesión que posees en la piel es un tipo de cancer (melanoma y no melanomas). Para lograrlo, se centrará en el desarrollo y la implementación de un sistema de detección basado en Deep Learning y visión por computadora.

Capítulo 2

MARCO TEÓRICO

2.1. Antecedentes de la investigación

En esta sección se presentarán diversos artículos de investigación o tesis las cuales abordarán el tema de la investigación que se tratara, la problemática y las técnicas que se emplearon para afrontar estas. Asimismo, a continuación se presenta un cuadro resumen (véase Anexo [D.2](#)) de lo que se presenta en esta sección.

2.1.1. Deep Learning-Based Transfer Learning for Classification of Skin Cancer (jain2021deep)

jain2021deep realizaron un artículo de investigación el cual fue publicado en la revista «Machine Learning with Applications» en el año 2021. Este fue titulado **jain2021deep** la cual traducida al español significa «Aprendizaje por transferencia basado en aprendizaje profundo para la clasificación del cáncer de piel».

2.1.1.1. Planteamiento del Problema y objetivo

El estudio se enfocó en mejorar el diagnóstico temprano del cáncer de piel, que es una de las principales preocupaciones de salud debido a su creciente incidencia. Por ello, el objetivo principal del estudio fue evaluar el rendimiento de diferentes arquitecturas de redes neuronales convolucionales pre-entrenadas. Buscando determinar cuál de estos lograba la mejor precisión en la clasificación

2.1.1.2. Metodología empleada por los autores

- Recopilación de la data: Se uso un conjunto de datos HAM10000 compuesta por 10015 imágenes dermatoscópicas y siete clases diferentes
- Preprocesamiento: Para evitar los problemas de desequilibrio y duplicados en el conjunto de datos, aplicaron técnicas de aumento de datos.
- Entrenamiento de modelos: Se implementaron diferentes arquitecturas como: VGG19, InceptionV3, InceptionResNetV2, ResNet50, Xception y MobileNet. Además que se usaron Adam (Adaptive Moment Estimation) y función de pérdida de Entropía Cruzada Categórica. (Categorical Cross-Entropy Loss) para realizar ajustes de Hiperparámetros.

2.1.1.3. Resultados obtenidos

Se concluyó que Xception Net supera al resto de las redes de aprendizaje de transferencia utilizadas en el estudio, con los valores más altos de Accuracy, Avg. Recall, Avg. Precision y Avg. F-Measure.

Model	Accuracy	Avg. Recall	Avg. Precision	Avg. F-Measure
VGG19	0.6754	0.6734	0.8548	0.7479
InceptionV3	0.8640	0.8619	0.8769	0.8713
InceptionResnetV2	0.8840	0.8762	0.8793	0.8845
ResNet50	0.8232	0.8222	0.8680	0.8416
Xception	0.8966	0.8957	0.8876	0.8902
MobileNet	0.8721	0.8711	0.8838	0.8740

Figura 2.1: Comparación de los resultados de los modelos utilizados. Fuente: **jain2021deep**

2.1.2. Skin cancer classification via convolutional neural networks: systematic review of studies involving human experts (haggenmuller2021skin)

haggenmuller2021skin realizaron un artículo de investigación el cual fue publicado en la revista «European Journal of Cancer» en el año 2021. Este fue titulado **haggenmuller2021skin** la cual traducida al español significa «Clasificación del cáncer de piel mediante redes neuronales convolucionales: revisión sistemática de estudios en los que participan expertos humanos».

2.1.2.1. Planteamiento del Problema y objetivo

El estudio se enfoca en realizar un análisis de las investigaciones sobre estudios que involucren melanoma y evaluar su posible relevancia clínica mediante tres aspectos principales: características del conjunto de pruebas, prueba entorno y representatividad de los médicos participantes.

2.1.2.2. Metodología empleada por los autores

- Base de datos: Se examinaron los artículos publicados en las siguientes fuentes: PubMed, Medline y ScienceDirect en busca de estudios publicados entre 2017 y 2021.
- Requisitos para entrar a la investigación: Solo se incluían estudios se realizaba comparación directa de los resultados de la IA con médicos y que tenían como objetivo principal una clasificación diagnóstica.

2.1.2.3. Resultados obtenidos

Solo un total de 19 estudios de lectores cumplieron los criterios de inclusión, de los cuales 11 enfoques basados en CNN abordaron la clasificación de imágenes dermatoscópicas, 6 se concentraron en la clasificación de imágenes clínicas, y 2 estudios dermatopatológicos utilizaron imágenes histopatológicas completas digitalizadas.




Figura 2.2: Representación de los 19 estudios. Fuente: **haggenmuller2021skin**

2.1.3. An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models (ali`2021enhanced)

ali`2021enhanced realizaron un artículo de investigación el cual fue publicado en la revista «Machine Learning with Applications» en el año 2021 publicada por El servier. Este fue titulado **ali`2021enhanced** la cual traducida al español significa «Una técnica mejorada de clasificación del cáncer de piel que utiliza una red neuronal convolucional profunda con modelos de aprendizaje por transferencia».

2.1.3.1. Planteamiento del Problema y objetivo

El cáncer de piel es uno de los tipos de cáncer de más rápido crecimiento y que puede causar la muerte, la realización de una detección temprana mejoraría significativamente las posibilidades de supervivencia del paciente. Por ello, el objetivo que se plantea es desarrollar un modelo de clasificación con la finalidad que distinguir las lesiones cutáneas benignas y malignas de forma precisa.

2.1.3.2. Metodología empleada por los autores

- Adquisición de la data: Se uso una base de datos llamada HAM10000 compuesta por 10015 imágenes dermatoscópicas. Donde las imagenes fueron clasificados como malignas o benignas.
- Preprocesamiento: Se realizo diferentes tecnicas de pre-procesamiento como: reducción de datos, eliminación de burbujas de aire, ruido y artefactos, normalización de los datos y «data augmentation» . Esto con la finalidad de mejorar la tasa de clasificación del conjunto de datos en general.
- Extracción de características: Se realizó una extracción de características para identificar y reconocer patrones en el conjunto de datos.
- Implementación del modelo: Se entreno la red neuronal convolucional profunda (DCNN) y otro grupo de modelos para comprar AlexNet, ResNet, VGG-16, DenseNet, MobileNet. Se hizo 3 diviciones del conjunto de datos: entrenamiento, validación y prueba de 2 formas distintas.
 - 70 % entrenamiento, 20 % validación, 10 % prueba
 - 80 % entrenamiento, 10 % validación, 10 % prueba




Figura 2.3: Modelo de arquitectura propuesto DCNN .Fuente: ali`2021enhanced

2.1.3.3. Resultados obtenidos

Según el artículo el modelo propuesto DCNN fue el que obtuvo una precisión de clasificación del 93.16 % en el conjunto de entrenamiento y 91.93 % en el conjunto de prueba. A comparación del rendimiento que tuvieron los otros modelos de transfer learning como AlexNet, ResNet, VGG-16, DenseNet y MobileNet, los cuales fueron inferiores en términos de precisión, recall, puntaje F1 y tiempo de ejecución.

The performance comparison between our proposed DCNN model and transfer learning models taking 70% of training, 20% of validation and 10% of testing data.

Model	Precision	Recall	F1 score	Training Acc	Testing Acc
AlexNet (Han, Zhong, Cao, & Zhang, 2017)	96.89	90.70	93.70	92.05	88.81
ResNet (Targ, Almeida, & Lyman, 2016)	84.94	97.50	90.79	92.78	85.20
VGG-16 (Guan et al., 2019)	88.27	95.18	91.59	88.83	86.09
DenseNet (Carcagni et al., 2019)	91.00	91.75	91.37	91.36	85.25
MobileNet (Sinha & El-Sharkawy, 2019)	84.62	94.57	89.32	92.93	82.62
Proposed DCNN model	94.63	93.91	94.27	92.69	90.16

Figura 2.4: Resultados de modelo DCNN comparandolo con otros modelos Fuente: ali`2021enhanced

2.1.4. Design of a tool for the classification of skin cancer images using Deep Neural Networks (DNN) (vargas`2021diseno)

vargas`2021diseno realizaron un artículo de investigación el cual fue publicado en la revista «Ciencia y Tecnología» en el año 2021 publicada por Universidad de Palermo (UP). Este fue titulado vargas`2021diseno.

2.1.4.1. Planteamiento del Problema y objetivo

Los autores identifican que el cáncer de piel es una enfermedad común a nivel mundial que requiere un diagnóstico temprano para mejorar la calidad de vida de los pacientes. La clasificación automática de lesiones cutáneas presenta un reto debido a su amplia variedad y morfología. Por ende, el objetivo de la investigación es utilizar las ventajas del Deep Learning con la finalidad de desarrollar una red neuronal convolucional (CNN) entrenada para la clasificación de lesiones cutáneas benignas y malignas.

2.1.4.2. Metodología empleada por los autores

- **Recopilación de la data:** Se uso dos bases de datos entre ellas HAM10000 compuesta por 10015 imágenes dermatoscópicas y ISIC (The International Skin Imaging Collaboration) la cual consta de 2357 imágenes de 226x226 píxeles de enfermedades oncológicas malignas y benignas.
- **Preprocesamiento:** Se aplicó Transfer Learning para compartir características generales de bases de datos extensas, mejorando el rendimiento. Haciendo uso de estrategias como Data Augmentation, ajuste de la tasa de aprendizaje y validación K-fold se implementaron para mejorar los modelos.
- **Selección de arquitectura:** Evaluaron diferentes arquitecturas como MobileNet V1, MobileNet V2, VGG19, VGG16, Inception V3, ResNet50. Al final se seleccionaron MobileNet V1 e Inception V3 como las arquitecturas más adecuadas
- **Implementación del modelo:** Se implementaron diferentes versiones de modelos, desde el entrenamiento sin congelar capas hasta la adición de capas ocultas y estrategias de regularización. Para evaluar cual es el mejor modelo.

2.1.4.3. Resultados obtenidos

El modelo MobileNet V1 alcanzó el mejor rendimiento a comparación de Inception V3. Este con un puntaje F1 del 91.06 %, una sensibilidad del 91.98 % y una tasa de falsos positivos del 9.65 %.

Model	Version	Acc (Val)	Loss (Val)
MobileNet V1	v1	0.8807	0.7560
MobileNet V1	v2	0.8883	0.5709
MobileNet V1	v2b	0.8788	0.6869
Inception V3	v1	0.8390	0.6038
Inception V3	v2	0.8252	0.4193
Inception V3	v2b	0.8845	0.4320
MobileNet V1	v3	0.8614	0.4768
Inception V3	v3	0.8561	0.3826
MobileNet V1	v4	0.8990	0.4795
Inception V3	v4	0.8516	0.3279
MobileNet V1	v5	0.9295	0.2074
Inception V3	v5	0.9064	0.3312

Figura 2.5: Comparacion de los resultados del modelo MobileNet V1 y Inception V3 con diferentes versiones. Fuente: **vargas'2021diseno**

2.1.5. Diagnosis of skin cancer using machine learning techniques (murugan'2021diag

murugan'2021diagnosis realizaron un artículo de investigación el cual fue publicado en la revista «Microprocessors and Microsystems» en el año 2021. Este fue titulado **murugan'2021diagnosis** la cual traducida al español significa «Diagnóstico del cáncer de piel mediante técnicas de aprendizaje automático».

2.1.5.1. Planteamiento del Problema y objetivo

El artículo destaca el problema de la detección temprana del cáncer de piel, ya que la piel desempeña un papel vital en el cuerpo humano y cualquier cambio en su funcionamiento puede afectar significativamente la salud general.

Enfocandose que las lesiones cutáneas que son signos clínicos importantes de enfermedades de la piel, como el melanoma y el carcinoma de células basales. Estos son una forma peligrosa de cáncer que puede propagarse rápidamente si no se detecta a tiempo

Por ende, el objetivo principal del estudio es desarrollar un sistema de identificación de enfermedades de la piel basado en imágenes de la piel. Empleando técnicas de aprendizaje automático como SVM, PNN y Random Forest

2.1.5.2. Metodología empleada por los autores

- **Recopilación de la data:** En este caso no se especifica el tamaño o la fuente exacta del conjunto de datos. Sin embargo, menciona que se empleó un conjunto de datos de imágenes dermoscópicas para identificar y clasificar diferentes tipos de lesiones de piel, como lentigo simple, melanoma, carcinoma basocelular, entre otros.
- **Preprocesamiento:** Se dividió en dos etapas:
 - Primera etapa: Removieron el ruido de las imágenes para eliminar pelos y burbujas que pueden afectar la extracción de características, utilizando un filtro de mediana.
 - Segunda etapa: Uso del algoritmo de segmentación Mean Shift para separar la región de interés (ROI) que contiene la lesión del fondo de la imagen.
- **Extracción de características:** Uso de tres técnicas para la extracción de características de las imágenes:
 - Gray Level Co-Occurrence Matrix (GLCM)
 - Moment Invariants(MI)
 - Gray Level Run Length Matrix (GLRLM)
- **Implementación del modelo:** Se aplican técnicas de clasificación como Máquinas de Vectores de Soporte (SVM), Redes Neuronales Probabilísticas y Bosques Aleatorios, así como la combinación de SVM y Random Forest, con las distintas técnicas para las características extraídas.

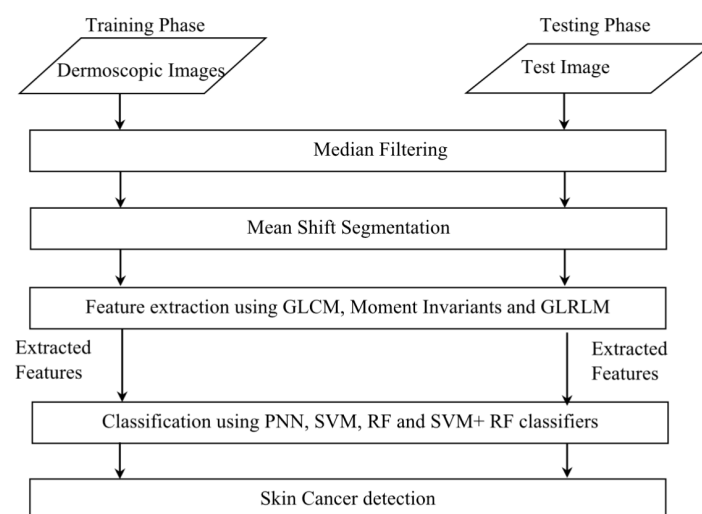


Figura 2.6: Grafica de la Metodología usada . Fuente: **murugan`2021diagnosis**

2.1.5.3. Resultados obtenidos

El rendimiento de los modelos que se emplearon se evaluó en términos de métricas como precisión, sensibilidad y especificidad. Dado como resultado que el mejor clasificador fue la combinación de SVM y Random Forest (SVM+RF) usando un extractor de características GLCM dando un accuracy de 89.31 %

Accuracy of various Classifiers.

FeaturesClassifiers	GLCM	MOMENT INVARIANT	GLRLM
PNN	63.25	56.94	61.93
RF	76.36	69.31	71.25
SVM	87.8	82.26	84.7
SVM+RF	89.31	84.63	86.12

Figura 2.7: Comparación de los modelos empleados con las tres técnicas para la extracción de características. Fuente: **murugan'2021diagnosis**

2.1.6. Multiclass skin cancer classification using EfficientNets – a first step towards preventing skin cancer (ali'2022multiclass)

ali'2022multiclass realizaron un artículo de investigación el cual fue publicado en la revista «Neuroscience Informatics» en el año 2022. Este fue titulado **ali'2022multiclass** la cual traducida al español significa «Clasificación de cáncer de piel multiclase utilizando redes eficientes: un primer paso para prevenir el cáncer de piel».

2.1.6.1. Planteamiento del Problema y objetivo

La clasificación del cáncer de piel presenta una alta dificultad debido a la variabilidad en la apariencia de sus diversas categorías diagnósticas. Aunque los dermatólogos suelen diagnosticar esta enfermedad visualmente, estudios recientes han demostrado que el uso de la tecnología pueden superar ayudar a los dermatólogos.

El objetivo principal es desarrollar un sistema de clasificación de cáncer de piel utilizando la técnica de transfer learning en redes neuronales convolucionales pre-entrenadas.

2.1.6.2. Metodología empleada por los autores

- **Adquisición de la data:** Se uso una base de datos llamada HAM10000 compuesta por 10015 imágenes dermatoscópicas. De donde se dibirieron las imagenes en siete difetentes tipos de cancer de piel
- **Preprocesamiento:** Primero se elimino la precencia de elemenotos no relevantes, en este caso los pelos que aparecia en la mayoria de las imagenes. Continuando con la redimensionción de las imagenes de acuerdo con los requerimientos de cada variante de EfficientNet (B0-B7). Finalizando con el aumento de datos para tener la misma cantidad en cada partición.
- **Entrenamiento y validación:** Los modelos se entrenaron y validaron utilizando técnicas como k-Fold Cross-Validation y se evaluaron con métricas como precisión, recall, exactitud y puntaje F1.

2.1.6.3. Resultados obtenidos

Según la tabla de resultados se concluyó que el modelo EfficientNet B4 logró los mejores resultados con un puntaje F1 del 87 % y una exactitud de clasificación Top-1 del 87.91 %, destacando su eficacia en la clasificación multiclase del cáncer de piel en el conjunto de datos HAM10000.

Model Wise Precision, Recall, F1 Score, Specificity, and Roc_Auc Comparisons.

Models	Precision	Recall	F1 score	Specificity	Roc_Auc
EfficientNet B0	84%	83%	82%	84%	95.94%
EfficientNet B1	85%	84%	83%	84%	96.10%
EfficientNet B2	85%	84%	84%	86%	96.36%
EfficientNet B3	87%	84%	84%	91%	96.67%
EfficientNet B4	88%	88%	87%	88%	97.53%
EfficientNet B5	88%	88%	87%	88%	97.54%
EfficientNet B6	86%	85%	85%	89%	96.76%
EfficientNet B7	86%	86%	85%	87%	97.23%

Figura 2.8: Comparación de los modelo empleados con las tres técnicas para la extracción de características. Fuente: [ali`2022multiclass](#)

2.1.7. Skin cancer classification using explainable artificial intelligence on pre-extracted image features (khater2023skin)

khater2023skin realizaron un artículo de investigación el cual fue publicado en la revista «Intelligent Systems with Applications» en el año 2023. Este fue titulado **khater2023skin** la cual traducida al español significa «Clasificación del cáncer de piel utilizando inteligencia artificial explicable en características de imágenes previamente extraídas».

2.1.7.1. Planteamiento del Problema y objetivo

Los autores plantearon la necesidad de desarrollar un modelo de clasificación de cáncer de piel que no solo sea preciso sino también explicativo. Esto usando inteligencia artificial explicativa (XAI) para clasificar lesiones de piel en tres clases: nevus típico, nevus atípico y melanoma

2.1.7.2. Metodología empleada por los autores

- Recopilación de la data: Se uso un conjunto de datos PH2(recopilación de datos en el departamento de dermatología del Hospital Pedro Hispano) Este conjunto de datos contiene imágenes dermatoscopia con siete características de entrada y una característica de salida.
- Preprocesamiento: El conjunto de datos se sometio a un proceso de preprocesamiento para mejorar su calidad y preparación para el análisis.
- Extracción de características: Se extrajeron características clave de las imágenes y usando el método chi-cuadrado se estimo la importancia de cada una de las características y se selecciono las más significativas.
- Entrenamiento de modelos de ML: Se entrenaron varios algoritmos de aprendizaje automático (ML) utilizando las características pre-extraídas. Los algoritmos incluyen KNN, XG-boost, árboles de decisión, y bosques aleatorios.

2.1.7.3. Resultados obtenidos

El modelo XG-boost como para el Random Forest alcanzó una precisión del min de 94 %.




Figura 2.9: Comparación de los modelos empleados con las tres técnicas para la extracción de características. Fuente: **ali`2022multiclass**

2.1.8. An improved transformer network for skin cancer classification (xin2022improved)

xin2022improved realizaron un artículo de investigación el cual fue publicado en la revista «Computers in Biology and Medicine» en el año 2022. Este fue titulado **xin2022improved** la cual traducida al español significa «Una red de transformadores mejorada para la clasificación del cáncer de piel».

2.1.8.1. Planteamiento del Problema y objetivo

El artículo se centra en la necesidad de mejorar la clasificación de imágenes de cáncer de piel para su diagnóstico temprano. Debido al aumento de su incidencia en todo el mundo, lo que representa una gran amenaza para la salud humana. En el documento se propone desarrollar un modelo de red transformadora mejorada que pueda lograr una mayor precisión en la clasificación de diferentes tipos de cáncer de piel, mediante el uso de una red neuronal transformadora de visión (VIT).

2.1.8.2. Metodología empleada por los autores

- **Recopilación de la data:** Se usó un conjunto de datos HAM10000 del archivo ISIC, que incluye siete clases exclusivas de cáncer de piel y recolección de imágenes de cáncer de piel de pacientes hospitalarios mediante dermatoscopia, incluyendo tres tipos de cáncer de piel típicos.
- **Preprocesamiento:** Se llevaron a cabo tres trabajos con la base de datos. Primero, la normalización, para limitar los datos preprocesados a un rango específico y eliminar singu-

laridades y efectos adversos causados por los datos de muestra. Segundo, el aumento de datos, que incluyó técnicas como volteo horizontal y vertical, recorte aleatorio, rotación aleatoria y ajuste de color para mejorar la diversidad de los datos. Por ultimo, el muestreo equilibrado, para garantizar una distribución equitativa de las clases en el conjunto de datos.

- Extracción de características: Uso de un transformador de visión multi-escala para dividir una imagen en diferentes tipos de parches. Permitiendo capturar características a múltiples escalas preservando la estructura de los bloques de imagen adyacentes.
- Entrenamiento de modelos: Se evaluó el modelo propuesto Modelo VIT (Vision Transformer) utilizando métricas como precisión, recuperación, puntaje F1 y AUC en los conjuntos de datos HAM10000 y el conjunto de datos clínico recopilado. Después se comparó el rendimiento del modelo propuesto con otros modelos existentes los cuales fueron soft attention network, Ensembles of multi-resolution (EfficientNets), Single model deep learning, Data augmentation for skin classification, Two path CNN model, Deep CNN (Baseline), MobileNetV2, ResNet50, InceptionV2. Con la finalidad de demostrar su eficacia y generalización.

2.1.8.3. Resultados obtenidos

El modelo VIT logró un AUC de 0.987, una precisión de 0.941 en el conjunto de datos clínicos recopilados y una precisión de 0.943 en el conjunto de datos HAM10000, superando en 0.3 %, 4.6 %, 1.3 %, 1.2 % y 0.8 % respectivamente a otros modelos.

Model	AUC	Precision	Accuracy
Soft attention network [21]	0.984	0.937	0.934
Ensembles of multi-resolution EfficientNets [31]	0.941	–	0.926
Single model deep learning [32]	0.974	–	0.864
Data augmentation for skin classification [33]	0.975	–	0.853
Two path CNN model [34]	–	–	0.886
Deep CNN (Baseline) [35]	0.979	0.890	–
VIT model	0.983	0.935	0.936
Proposed VIT model	0.987	0.941	0.943

Figura 2.10: Resultados de los Modelo empleados. Fuente: **xin2022improved**

2.1.9. Uncertainty quantification in skin cancer classification using three-way decision-based Bayesian deep learning (abdar2021uncertainty)

abdar2021uncertainty realizaron un artículo de investigación el cual fue publicado en la revista «Computers in Biology and Medicine» en el año 2022. Este fue titulado **abdar2021uncertainty** la cual traducida al español significa «Cuantificación de la incertidumbre en la clasificación del cáncer de piel mediante aprendizaje profundo bayesiano de tres vías basado en decisiones».

2.1.9.1. Planteamiento del Problema y objetivo

Los autores se enfocan en la necesidad de cuantificar la incertidumbre en la clasificación de imágenes de cáncer de piel utilizando deep learning, enfocado en la toma de decisiones médicas. Por ello, su objetivo principal es diseñar y validar un nuevo modelo de cuantificación de incertidumbre basado en la teoría de la decisión trinaría y deep learning para mejorar la confiabilidad y la conciencia de la incertidumbre en la clasificación de imágenes médicas.

2.1.9.2. Metodología empleada por los autores

- **Recopilación de Datos:** Los autores recopilaron dos conjuntos de datos de 2 partes: uno de Kaggle y otro del ISIC 2019. Los cuales se realizó un preprocesamiento para preparar las imágenes para su análisis.
- **Selección de Arquitecturas de Deep Learning:** Se seleccionaron cuatro arquitecturas de deep learning conocidas (ResNet152V2, MobileNetV2, DenseNet201 e InceptionResNetV2) como modelos preentrenados en ImageNet. Donde se usó la Optimización Bayesiana (BO) para determinar los mejores valores de hiperparámetros para cada arquitectura y conjunto de datos.
- **Modelo de tres fases:** Se implementó un modelo de tres fases que incluye la detección de muestras inciertas, la clasificación inicial y la clasificación final. Se utilizó un modelo de decisión basado en tres vías (TWDBDL) que combina métodos de incertidumbre con redes neuronales profundas para mejorar la clasificación de cáncer de piel. En la segunda fase, se empleó un modelo de conjunto (EMC) con diferentes arquitecturas de redes neuronales para procesar los datasets. La TWD se utilizó para mejorar la precisión y confiabilidad de las predicciones del modelo al integrarla con las técnicas de cuantificación de incertidumbre en el modelo de aprendizaje profundo.

2.1.9.3. Resultados obtenidos

Para el primer dataset: En la primera fase, el método DE (Deep Ensemble) aplicado a modelos como ResNet152V2, DenseNet201, InceptionResNetV2 y MobileNetV2 logró una precisión del 87.55 %. En la segunda fase, el método EMC (Ensemble Monte Carlo Dropout) obtuvo la mejor AUC, mientras que la precisión de la clase 1 (casos malignos) fue menor.

Para el segundo dataset: En la primera fase, el método EMC aplicado a modelos como ResNet152V2, DenseNet201 y DenseNet201 obtuvo una precisión del 89.39 % y un F1-score del 92 %. En la segunda fase, también se utilizó EMC. En la fase final, la precisión de la clase 0 (casos de melanoma) se mantuvo estable, mientras que la precisión de la clase 1 (casos no melanoma) aumentó.

En resumen el modelo TWDBDL propuesto logró buenos resultados de precisión, F1-score y AUC en la clasificación de cáncer de piel, especialmente al detectar y manejar adecuadamente las muestras inciertas.

Table 7

The results obtained in the first classification phase of the proposed TWDBDL model applied to two considered skin cancer datasets. In this table, f1-0 is the F1-score of class 0, f1-1 is the F1-score of class 1 and F1-score is the overall F1-score.

Datasets	Method	EC	EI	STD-Co	STD-In	f1-0	f1-1	Accuracy (%)	F1-score (%)	AUC
First	TWDBDL (DE)	0.6207	0.6335	0.1351	0.2377	91.00	89.00	87.55	90.19	0.9377
Second	TWDBDL (EMC)	2.624	2.835	0.4707	0.4934	91.00	92.00	89.39	92.00	0.9700

Figura 2.11: Resultados de los Modelo empleados. Fuente: **abdar2021uncertainty**

2.1.10. A multi-class skin Cancer classification using deep convolutional neural networks (chaturvedi2020multi)

chaturvedi2020multi realizaron un artículo de investigación el cual fue publicado en «Springer Science+Business Media, LLC, part of Springer Nature 2020» en el año 2020. Este fue titulado **chaturvedi2020multi** la cual traducida al español significa «Una clasificación de cáncer de piel de múltiples clases utilizando redes neuronales convolucionales profundas».

2.1.10.1. Planteamiento del Problema y objetivo

El estudio se enfoca en relajar una clasificación precisa de diferentes tipos de cáncer de piel utilizando técnicas de aprendizaje profundo, ya que se requiere un diagnóstico temprano y preciso para asegurar un tratamiento efectivo para los pacientes. Por ello, la investigación, busca desarrollar un sistema basado en aprendizaje profundo que clasifique múltiples clases de

cáncer de piel con alta precisión, apoyando la mejorar, eficiencia y precisión del diagnóstico, lo que en última instancia resultará en una atención médica superior para los pacientes con cáncer de piel.

2.1.10.2. Metodología empleada por los autores

- **Recopilación de la data:** Se uso los siguetes conjuntos de datos: ISIC2017, ISIC2018, y HAM10000. Donde se realizó ajustes para asegurar que los datos estén en un formato adecuado para el entrenamiento de los modelos.
- **Implementación de Modelos:** Se utilizan diferentes arquitecturas de redes neuronales convolucionales profundas como Xception, InceptionV3, ResNetXt101, InceptionResNetV2 y NASNetLarge para la clasificación de siete tipos de cáncer de piel.
- **Optimización de Modelos(hiperparametros):** Se emplean optimizadores como stochastic gradient descent with momentum (SGDM) y adaptive moment estimation (Adam) para ajustar los modelos y minimizar la función de pérdida.
- **Evaluación de Desempeño:** Se evalúa el desempeño de los modelos en un conjunto de validación de 1103 imágenes, calculando métricas como recall, precision, exactitud (accuracy) y F1-score para cada modelo y para las combinaciones de modelos de ensemble.

2.1.10.3. Resultados obtenidos

El accuracy más alto se logró con el modelo ResNeXt101 y InceptionResNetV2, en ambos casos con un 93.20. No obstante ResNeXt101 consiguió una mejor precisión que InceptionResNetV2 por una diferencia de 1 %.

Multimedia Tools and Applications

Table 1 Accuracy, Weighted Average of Precision, Recall and F1-score for HAM10000 dataset of independent model

Method	Accuracy (%)	Weighted Average		
		Precision (%)	Recall (%)	F1-score (%)
InceptionV3	91.56	89	89	89
ResNetXt101	93.20	88	88	88
InceptionResNetV2	93.20	87	88	88
Xception	91.47	89	88	88
NASNetLarge	91.11	86	86	86

Figura 2.12: Resultados de los Modelo empleados. Fuente: **chaturvedi2020multi**

2.2. Bases Teóricas

2.2.1. Inteligencia Artificial

La inteligencia artificial (IA) es un campo de la informática que se concentra en crear sistemas y programas capaces de realizar tareas similares a como lo haría un ser humano. Estos sistemas están diseñados para aprender de datos, reconocer patrones, tomar decisiones y adaptarse y mejorar con la experiencia.

El termino Inteligencia Artificial fue dado a conocer en el año 1956 durante la Conferencia Dartmouth en Hanover, Nuevo Hampshire (Estados Unidos), donde se propuso la posibilidad de crear una máquina que pudiera pensar como un ser humano. No obstante, esta a estado presente mucho antes desde de trabajos de investigación, hasta en el cine y novelas representando como ciencia ficción. Actualmente, se ha convertido en una de las tecnologías revolucionarias y de mayor interés de investigación.

2.2.2. Aprendizaje Automático (Maching Learning)

Es un subcampo de la inteligencia artificial que se centra en el desarrollo de algoritmos y modelos. Permitiendo a las computadoras aprender a partir de datos ya etiquetados y tomar decisiones según la información brindada, esto identificando patrones en los datos y utilizando estos para hacer predicciones o tomar decisiones. Este tiende a aplicarse en los siguientes temas: detección de fraudes, predicciones, clasificación, sistemas de recomendación. Este aprendizaje requiere datos de entrenamiento para que funcionen, ademas de mayormente trabajar con data estructurada.

2.2.3. Aprendizaje Profundo (Deep Learning)

Es un subcampo del aprendizaje automático que utiliza redes neuronales artificiales con múltiples capas (profundas) para modelar y resolver problemas complejos. Las redes neuronales profundas se caracterisan por la necesidad de recibir grandes conjuntos de datos estos pueden ser estructurados o no estructurado. Con la finalidad de aprender representaciones jerárquicas de los datos, lo que permite la automatización de la extracción de características. Este tiende a aplicarse en los siguientes temas: Reconocimiento de voz y visión por computadora, procesamiento de lenguaje natural (NLP), Diagnóstico médico, conducción autónoma, entre otros.

2.2.4. Computer Vision

Se centra en entrenar a las máquinas para que interpreten las imágenes o videos de manera similar a como lo hacen los humanos. Esto implica la adquisición, el procesamiento, el análisis y la comprensión de imágenes y datos visuales para automatizar tareas que requieren la visión humana. Algunas tecnologías y algoritmos en esta área son:

- Comparación estadística: Los algoritmos son capaces de realizar comparaciones y análisis detallados de los objetos, más allá de ubicarlos en un plano.
- Detección de objetos: Los algoritmos son capaces de localizar y clasificar varios objetos en una imagen o en videos. Algunos algoritmos son YOLO (You Only Look Once), SSD (Single Shot MultiBox Detector), Faster R-CNN
- Análisis de Movimiento: Capacidad de seguir el movimiento y la dirección de un objeto o personas en una secuencia de video. Ejemplos: Optical Flow, Tracking algorithms (Kalman Filter, Mean-Shift, etc.).

2.3. Marco Conceptual

2.3.1. El Cáncer

Según la página del Instituto nacional del cáncer esta enfermedad se caracteriza por la multiplicación de algunas células anormales o dañadas del cuerpo humano, que se dispersan a otras partes del organismo. Llegando a formar tumores. (**cncer'2024**) El origen de este puede atribuirse a errores en la división celular, factores hereditarios o influencias externas como el entorno y la exposición a sustancias químicas. El desarrollo del cáncer es único en cada individuo, ya que cada persona tiene combinaciones genéticas diferentes, lo que hace que el tratamiento no sea igual para todos los casos.

2.3.2. Cáncer de Piel

El cáncer de piel es el tipo de cáncer más prevalente a nivel mundial. Si bien algunas personas presentan un riesgo de contraerlo, puede afectar a cualquier persona. Este se origina a partir de la formación de células malignas en el tejido cutáneo. Suele desarrollarse en áreas de la piel que están expuestas al sol; sin embargo, también puede aparecer en zonas que normalmente no están expuestas a la luz solar. Las principales causas del cáncer de piel se deben a la

exposición excesiva a los rayos UV del sol, así como al uso de camas bronceadoras y lámparas solares. Los rayos UV tienen la capacidad de dañar las células de la piel. A corto plazo, este daño puede resultar en quemaduras solares. Con el tiempo, la acumulación del daño por rayos UV provoca cambios en la textura de la piel, envejecimiento prematuro y, en ocasiones, cáncer de piel. (**cncer'piel'clinic'2024**)

2.3.3. Síntomas del Cáncer de Piel

Según la American Cancer Society, los médicos sugieren que los exámenes de la piel se incluyan en las revisiones médicas de rutina. De lo contrario, recomiendan que las personas examinen su propia piel aproximadamente una vez al mes. Este autoexamen debe realizarse frente a un espejo, en una habitación bien iluminada, para poder revisar cada área del cuerpo hasta las difíciles de ver. Es importante tener en cuenta la regla del "ABCDE" para identificar signos comunes de problemas en la piel: Asimetría, Borde, Color, Diámetro y Evolución. Estas pautas ayudan a detectar posibles irregularidades en la piel que podrían indicar la presencia de cáncer u otras afecciones. (**information'cancer**)

2.3.4. Tipos del Cáncer de Piel

El cáncer de piel se clasifica en dos grandes categorías: cáncer de piel de tipo no melanoma y cáncer de piel de tipo melanoma. El cáncer de piel de tipo no melanoma se subdivide en carcinomas de células basales y carcinomas de células escamosas. Aunque generalmente son malignos, pueden curarse; sin embargo, si no se tratan a tiempo, pueden causar desfiguración y resultar muy costosos de tratar. Por otro lado, el cáncer de piel de tipo melanoma es responsable de la mayoría de las muertes relacionadas con el cáncer de piel, debido a su tendencia a propagarse a otras partes del cuerpo, incluidos los órganos vitales.

2.3.5. Melanoma

El melanoma, también conocido como melanoma maligno y melanoma cutáneo, se origina a partir de los melanocitos, las células especializadas de la piel encargadas de producir melanina. La melanina es responsable del tono bronceado o rojizo que adquiere la piel al exponerse al sol. Este tipo de cáncer tiene un gran potencial maligno, siendo responsable de más del 90% Este comportamiento agresivo y su capacidad de propagarse rápidamente a otras partes del cuerpo, incluidos los órganos vitales, hacen que el melanoma sea especialmente peligroso y mortal, destacándose como una de las formas más graves de cáncer de piel.

2.3.6. Formas de diagnosticar el cáncer de piel

El primer paso en la detección de posibles problemas en la piel es realizar un examen con un médico especialista o alguien con conocimiento en el área. Durante este examen, se busca identificar cualquier lesión nueva o inusual. Si se encuentra alguna, el médico evaluará la lesión utilizando herramientas como el dermatoscopio, la dermatoscopia digital, la microscopía de reflectancia confocal o la ecografía cutánea. Sin embargo, para confirmar el diagnóstico, siempre es necesario realizar una biopsia de piel para su análisis en el laboratorio. Este procedimiento es actualmente la única manera de determinar con certeza si una persona tiene cáncer de piel y, en caso sea afirmativo, identificar el tipo específico de cáncer presente.

(clínica barcelona)

biblio/references

Anexos

Anexos A

Anexo I: Árbol de Problema




Figura A.1: Árbol de Problema. Fuente: Elaboración propia

Anexos B

Anexo II: Árbol de Objetivo

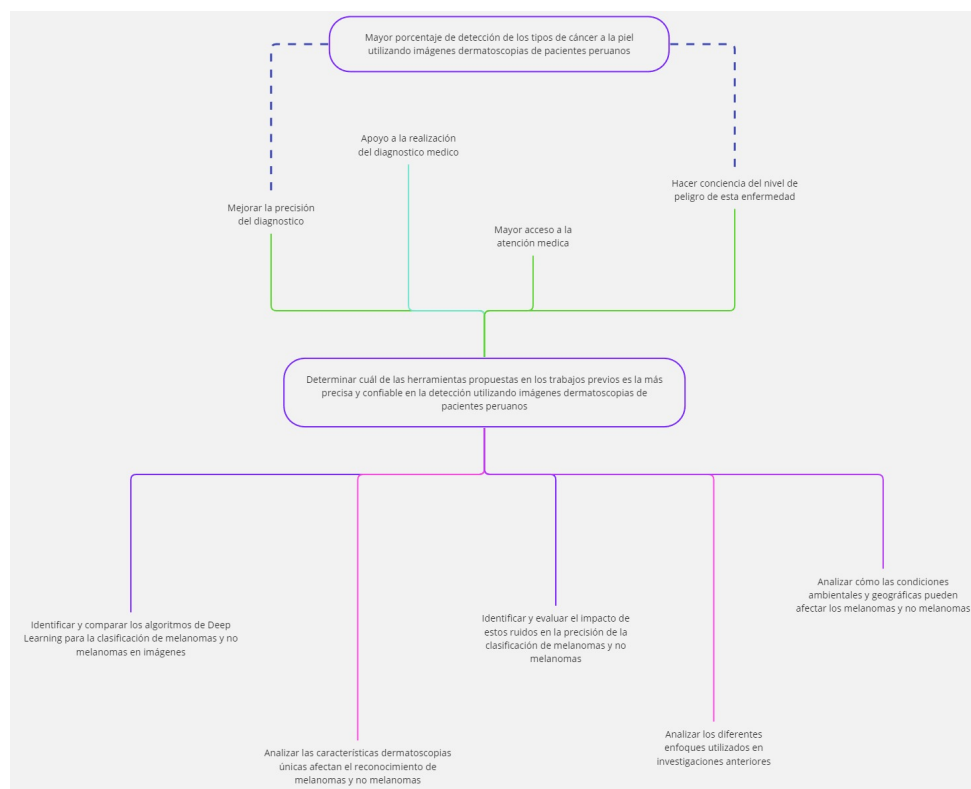


Figura B.1: Árbol de Problema. Fuente: Elaboración propia

Anexos C

Anexo II: Matriz de Consistencia

PROBLEMAS	OBJETIVOS	HIPÓTESIS
Problema General	Objetivo General	Hipótesis General
¿Es posible realizar un pre-diagnostico de cáncer de piel en el Perú haciendo uso de técnicas de Deep Learning y computer vision que identifique el Cáncer de Piel de tipo melanoma partir de imágenes dermatológicas?	Desarrollar un sistema que identifique el cáncer de piel de tipo melanoma a partir de imágenes dermatológicas mediante el uso de técnicas de Deep Learning y computer vision.	La aplicación de técnicas de Deep Learning en el análisis de imágenes dermatológicas permitirá entrenar un modelo capaz de identificar el cáncer de piel de tipo melanoma.
Problemas Específicos	Objetivos Específicos	Hipótesis Específicas
¿Cuáles son los algoritmos de Deep Learning que pueden clasificar con precisión el cáncer de piel de tipo melanoma en imágenes dermatológicas?	Identificar los algoritmos de Deep Learning más adecuados para la clasificación del Cáncer de Piel de tipo melanoma en imágenes dermatológicas.	La implementación del algoritmo de Deep Learning adecuado permitirá clasificar con precisión el Cáncer de Piel de tipo melanoma en imágenes dermatológicas.
¿Cómo evaluar la precisión de los modelos de Deep Learning en la detección de cáncer de piel de tipo melanoma?	Identificar que métricas usar para evaluar el rendimiento del modelo de Deep Learning en la detección del cáncer de piel de tipo melanoma	Indentificar las métricas nos proporcionara una mejor evaluación del modelo de Deep Learning en la detección de cáncer de piel de tipo melanoma.
¿Qué tipo de ruido pude haber en las imágenes dermatológicas que dificulté la detección del cáncer de piel de tipo melanoma?	Identificar que preprocesamiento reduce el impacto de los diferentes tipos de ruidos encontrados en las imágenes dermatológicas de cáncer de piel de tipo melanoma.	Identificar los tipos de ruidos en las imágenes dermatológicas permitirá tener un modelo con mayor precisión en la detección de cáncer de piel de tipo melanoma.
¿Cómo afecta la disponibilidad de la base de datos de imágenes dermatológicas en el desarrollo de un sistema de detección del cáncer de piel de tipo melanoma?	Identificar la base de datos de imágenes dermatológicas, mejorara el desarrollo del modelo de detección del cáncer de piel de tipo melanoma.	Indentificar la base de datos de imágenes dermatológicas mejorara la precisión en la detección del cáncer de piel de tipo melanoma.

Tabla C.1: Matriz de consistencia. Fuente: Elaboración propia

Anexos D

Anexo II: Resumen de Papers investigados

Tipo	Nº	Título	Autor	Año	País	Fuente
Problema	1	Deep Learning-Based Transfer Learning for Classification of Skin Cancer	Satin, J. , Udit, S., Balakrushna, T., Emad, A. Mohamed K. and Ali K.	2021	Arabia Saudita.	Sensors
	2	Skin cancer classification via convolutional neural networks: systematic review of studies involving human experts	S. Haggenu ller, A. Hekler, R.C. Maron, (...) , V.M. Rotenberg	2021	Europa	European Journal of Cancer
Propuesta	3	An enhanced technique of skin cancer classification using deep convolutional neural network with transfer learning models	Md Shahin Ali, Md Sipon Miah, Jahurul Haque, Md Mahbubur Rahman y Md Khairul Islam	2021	República de Irlanda	Machine Learning with Applications, 2021, vol. 5
	4	Design of a tool for the classification of skin cancer images using Deep Neural Networks (DNN)	Diana Paola Merchán Vargas, Helis Navarro Báez, Jaime Guillermo Barrero Pérez y Jeyson Arley Castillo Bohórquez	2021	Argentina	Ciencia y Tecnología”, número 21 del año 2021.
Técnica	5	Diagnosis of skin cancer using machine learning techniques	A. Murugan, S. Anu H. Nair y K.P. Sanal Kumar	2021	India	Microprocessors and Microsystems en 2021
	6	Multiclass skin cancer classification using EfficientNets – a first step towards preventing skin cancer	K. Ali, Z.A. Shaikh, A.A. Khan, S. Rathod, S. Das	2022	Pakistan	2022, revista Neuroscience Informatics
	7	Skin cancer classification using explainable artificial intelligence on pre-extracted image features	Khater, T., Ansari, S., Mahmoud, S., Hussain, A., Tawfik, H.	2017	Miratos Árabes Unidos	revista Intelligent Systems with Applications. ^{en} el año 2023 Association of Automation (YAC)
	8	An improved transformer network for skin cancer clas-	C. Xin, Y. Wang, G. Wang, X. Zhao, Y.	2022	China	Computers in Biology and Medicine